

$$\text{양성 샘플의 확률} = P(Y=1 | \vec{x}) = P$$

▶ 양성

$$\text{Odds ratio (오즈비)} = \frac{P}{1-P} = \frac{\text{양성일 확률}}{\text{음성일 확률}}$$

$$\frac{O}{1-O} = \frac{O}{1} = [0 \leq \text{오즈비} < \infty] \approx \frac{1}{O} = \frac{1}{1-O}$$

(단, $P \neq 0$ (by $\frac{P}{1-P} \neq 0$))

$$\text{logit}(P(Y=1 | \vec{x})) = \text{logit}(P) = \log \frac{P}{1-P}$$

$$= W_0 x_0 + W_1 x_1 + \dots + W_m x_m = \sum_{i=0}^m W_i x_i = \vec{W} \cdot \vec{x} = \vec{w}^T \vec{x}$$

▶ (단, $x_0 = 1$)

$$\log \frac{O}{1-O} = \log O \approx [-\infty < \text{logit}(P) < \infty] \approx \log \frac{1}{O} = \log \frac{1}{1-O}$$

$$\vec{w}^T \vec{x} = \text{logit}(P) = z \text{ 라 하자}$$

$\rightarrow P \neq 1$

$$\rightarrow \text{logit}(P) = \log \frac{P}{1-P} = z \rightarrow e^z = \frac{P}{1-P} \rightarrow e^z(1-P) = P$$

$$\rightarrow e^z - e^z P = P \rightarrow e^z = (1+e^z)P \rightarrow P = \frac{e^z}{1+e^z}$$

$$\rightarrow P = \frac{e^z}{1+e^z} = \frac{e^z(e^{-z})}{(1+e^z)(e^{-z})} = \frac{1}{e^{-z}+1}$$

$$\rightarrow P = P(Y=1 | \vec{x}) = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-\text{logit}(P)}} = \frac{1}{1+e^{-\vec{w}^T \vec{x}}}$$

$$P(Y=1 | \vec{x}) = \frac{1}{1+e^{-\vec{w}^T \vec{x}}} = \frac{1}{1+e^{-z}} = \phi(z) = \phi(\vec{w}^T \vec{x})$$

such that (s.t.)

$$P(Y=1 | \vec{x}; \vec{w}) = P(Y=1 | \vec{x}) = \phi(z) = \phi(\vec{w}^T \vec{x})$$

▶ 모수가 \vec{w} 일 때
 입력값이 \vec{x} 일 때
 $y=1$ 일 확률

모수가 \vec{w} 인 확률밀도함수 ϕ 는
 \vec{x} 입력되었을 때 $y=1$ 일 확률을
 함 수간으로 가짐

(가능도)
 최대 우도 추정법 (MLE) 으로
 입력데이터 \vec{x}_i 에 대응하는 y_i 데이터가 n 개 입력될 때
 $y=1$ 일 확률밀도함수 ϕ 의 모수 \vec{w} 을 추정해보자

→ Likelihood

$$\text{가능도 함수} = L(\vec{w}) = P(\vec{y} | \vec{x}; \vec{w})$$

→ 모수가 \vec{w} 일 때 \vec{x} 가 입력되었을 때 \vec{y} 가 나올 확률 (가능도)

$$\begin{aligned} L(\vec{w}) &= P(\vec{y} | \vec{x}; \vec{w}) = \prod_{i=1}^n P(y_i | \vec{x}_i; \vec{w}) \\ &\quad \text{→ } y = y_i \\ \text{모수 } \vec{w} \text{ 가 } \\ \text{변수 } &= \prod_{i=1}^n \left(P(y=1 | \vec{x}_i; \vec{w}) \right)^{y_i} \left(1 - P(y=1 | \vec{x}_i; \vec{w}) \right)^{1-y_i} \\ &= \prod_{i=1}^n (\phi(\vec{x}_i))^{y_i} (1 - \phi(\vec{x}_i))^{1-y_i} \\ &= \prod_{i=1}^n (\phi(\vec{w}^T \vec{x}_i))^{y_i} (1 - \phi(\vec{w}^T \vec{x}_i))^{1-y_i} \end{aligned}$$

→ 로그 가능도 함수
 가능도 (Likelihood) 를 Log 를 취해보자

→ Log Likelihood = $\ell(\vec{w}) = \log L(\vec{w})$

$$\begin{aligned} &= \log \prod_{i=1}^n (\phi(\vec{x}_i))^{y_i} (1 - \phi(\vec{x}_i))^{1-y_i} \\ &= \sum_{i=1}^n \left[\log \phi(\vec{x}_i)^{y_i} + \log (1 - \phi(\vec{x}_i))^{1-y_i} \right] \\ &= \sum_{i=1}^n \left[y_i \log (\phi(\vec{x}_i)) + (1-y_i) \log (1 - \phi(\vec{x}_i)) \right] \end{aligned}$$

이때 로그 가능도 함수 $\ell(\vec{w})$ 를 경사승강법을 활용하여
 극댓값을 찾게 하는 \vec{w} 를 찾는다. → 최대 로그 가능도 추정법!

⇒ $-\ell(\vec{w})$ 를 경사하강법을 활용하여

극솟값을 찾게 하는 \vec{w} 를 찾는다.

→ Cost function (비용함수) = $J(\vec{w}) = -\ell(\vec{w})$

$$\begin{aligned}
 J(\vec{w}) &= -\mathcal{L}(\vec{w}) = -\sum_{i=1}^n \left[y_i \log(\phi(z_i)) + (1-y_i) \log(1-\phi(z_i)) \right] \\
 &= \sum_{i=1}^n \left[-y_i \log(\phi(\vec{w}^T \vec{x}_i)) - (1-y_i) \log(1-\phi(\vec{w}^T \vec{x}_i)) \right] \\
 \rightarrow \frac{1}{n} J(\vec{w}) &= \text{Binary Cross Entropy (BCE)}
 \end{aligned}$$

$$\begin{aligned}
 \frac{\partial J}{\partial \vec{w}} &= -\frac{\partial \mathcal{L}}{\partial \vec{w}} = -\frac{\partial \mathcal{L}}{\partial \phi} \frac{\partial \phi}{\partial z_i} \frac{\partial z_i}{\partial \vec{w}} \\
 &= -\sum_{i=1}^n \left[\frac{\partial E_i}{\partial \phi} \frac{\partial \phi}{\partial z_i} \frac{\partial z_i}{\partial \vec{w}} \right] \\
 &= -\sum_{i=1}^n \left[\left(\frac{y_i}{\phi(z_i)} + \frac{(1-y_i)}{1-\phi(z_i)} \right) \phi(z_i)(1-\phi(z_i)) \vec{x}_i \right] = 0 \quad \text{??}
 \end{aligned}$$

다음은 \vec{w} 에 대한